

# Relazione Big Data

Corso di HPC

Università degli Studi di Salerno

Anno Accademico 2024/2025



**Docente:** Giuseppe D'aniello  
gi.daniello@unisa.it

**Studente:** Giulia Minichiello  
**Matricola:** 0622702127

# Chapter 1

## Descrizione del Dataset

Il dataset utilizzato per l'analisi di auto BMW è un file CSV denominato `BMW_Car_Sales.csv`. Include i seguenti campi:

- **Model:** Modello dell'auto BMW.
- **Year:** Anno di produzione dell'auto.
- **Region:** Regione geografica in cui è avvenuta la vendita.
- **Color:** Colore dell'auto.
- **Fuel\_Type:** Tipo di carburante utilizzato (Petrol, Diesel, Electric, Hybrid).
- **Transmission:** Tipo di trasmissione (Manual o Automatic).
- **Engine\_Size\_L:** Cilindrata del motore.
- **Mileage\_KM:** Chilometraggio dell'auto.
- **Price\_USD:** Prezzo dell'auto in dollari.
- **Sales\_Volume:** Volume delle vendite per il modello specifico.
- **Sales\_Classification:** Classificazione delle vendite (High, Low).

## Chapter 2

# Introduzione ad hadoop MapReduce

Hadoop MapReduce è un framework open-source progettato per l'elaborazione distribuita di grandi quantità di dati. Il modello MapReduce si basa su due fasi principali: la fase *Map*, in cui i dati vengono suddivisi e processati in parallelo, e la fase *Reduce*, in cui i risultati intermedi vengono aggregati per produrre l'output finale.

### 2.1 Esercizio 1- MapReduce

Realizzare un programma con MapReduce che identifichi i topK modelli con il maggior numero di vendite (campo `Sales_Volume`). Il programma dovrà aggregare i volumi di vendita per ciascun modello e restituire in output i K modelli che hanno totalizzato il maggior numero di vendite complessive.

#### 2.1.1 Soluzione

Il problema è stato risolto utilizzando due Job.

##### Pattern Utilizzati

Per risolvere questo problema utilizzando Hadoop MapReduce sono stati utilizzati i seguenti Pattern:

- **Job Chaining:** Utilizzato in modo tale che l'output di Job 1 diventi l'input di Job 2.
- **Numerical Summarization:** Applicato per aggregare i volumi di vendita per ciascun modello.
  - **Mapper:** Il mapper emette coppie (modello, sales\_volume);
  - **Combiner:** Il primo reducer viene utilizzato come Combiner nel Job 1, perché la somma è associativa e commutativa. Quindi somma localmente i valori con la stessa chiave.
  - **Reducer:** Il reducer usa la chiave come "group by" e somma le vendite per modello restituendo (modello, totale\_vendite).

Il Secondo Job è stato implementato con un filtering pattern per implementare topK

- **TopK:** Implementato per selezionare i K modelli con il maggior numero di vendite.
  - **Mapper:** ogni mapper crea la propria lista di topK modelli
  - **Reducer:** Il reducer combina le liste ricevute dai mapper per ottenere la lista finale.

Il numero di reducer scelto è 2 per il Job 1, per suddividere il carico tra più nodi, e 1 per il Job 2 per ottenere TopK globale.

### 2.1.2 Risultati

Di seguito sono riportati i risultati ottenuti dai due job.

```
3 Series      23281303
5 Series      23097519
7 Series      23786466
M3           22349694
M5           22779688
X1           23406060
X3           22745529
X5           22709749
X6           22661986
i3           23133849
i8           23423891
```

Figure 2.1: Figura1- output Job 1

```
7 Series      23786466
i8           23423891
X1           23406060
```

Figure 2.2: Figura2- output Job 2

## Chapter 3

# Apache Spark

Apache Spark è un framework open-source per l'elaborazione distribuita di dati su larga scala. Rispetto a Hadoop MapReduce, Spark offre prestazioni superiori grazie all'elaborazione in memoria.

### 3.1 Esercizio 2- Spark

La statistica che si è scelto di ricavare è un indice che stima quanto una regione sia "green" in relazione al numero di auto elettriche vendute dal 2015. Per la realizzazione dell'esercizio si è scelto di eliminare la riga di intestazione dal csv.

#### 3.1.1 Soluzione

Per calcolare l'indice "green" per ciascuna regione, si è proceduto come segue:

- Utilizzo del primo filtro per selezionare solo le auto con anno dal 2015.
- Poi è stato applicato un secondo filtro per considerare solo le auto elettriche.
- Ogni riga è stata trasformata nella coppia (regione,vendite) con la trasformazione "mapToPair".
- Le vendite per regione sono state sommate utilizzando la trasformazione "reduceByKey".
- Le coppie sono state invertite per poter utilizzare la sort,
- È stata utilizzata la trasformazione "sortByKey" per ordinare le regioni in base alle vendite in ordine decrescente.

#### 3.1.2 Risultati

Di seguito è riportato il risultato ottenuto dall'esecuzione del programma Spark.

```
(7371884,North America)
(7088248,Europe)
(7054010,Middle East)
(6977122,Asia)
(6869832,Africa)
(6862670,South America)
```

Figure 3.1: Figura3- output Spark